

UNIVERSIDADE DO VALE DO ITAJAÍ — UNIVALI

Escola Politécnica

Programa de Pós-Graduação em Computação Aplicada — PPGCA

Disciplina: Modelagem Estatística

Prof. Dr. Rodrigo Sant’Ana

Modelos Lineares Generalizados aplicados ao manejo fitossanitário da cafeicultura

Grupo 2 — Broca, ferrugem e padrão de exportação

Matheus Piotroski Neis · Letícia Zorzi Rama · André Ribeiro

Itajaí, Santa Catarina — Setembro de 2026

Uma cooperativa de cafeicultores de Minas Gerais enfrenta três problemas simultâneos que consomem seu orçamento técnico e definem sua margem:

- a **broca-do-café** (*Hypothenemus hampei*), monitorada por armadilhas instaladas em cada talhão;
- a **ferrugem alaranjada** (*Hemileia vastatrix*), avaliada pela severidade — a fração da área foliar lesionada;
- a **classificação do lote** para o mercado de exportação, que define o preço recebido.

O corpo técnico precisa decidir onde concentrar o esforço de manejo na próxima safra e que recomendações fazer aos cooperados quanto a cultivar, densidade de plantio, adubação e irrigação. O conjunto de dados reúne 340 talhões de café descritos por 19 variáveis agronômicas, climáticas e fitossanitárias. O talhão refere-se a determinada área da lavoura cafeeira que pode ser considerada homogênea, por ter a mesma variedade de café plantada na mesma data, em um solo de características físicas, químicas e topográficas semelhantes, além de receber o mesmo manejo agronômico e o mesmo tratamento administrativo (Santos *et al.*, 2009).

Três perguntas foram formuladas com base nos problemas:

- Quais condições de talhão favorecem a infestação pela broca, e quanto se ganha em pressão de praga ao alterar cada uma delas?
- Que fatores agronômicos determinam a severidade da ferrugem, e existe uma cultivar comprovadamente mais resistente?

- O que determina a chance de um lote atingir o padrão de exportação?

Tais perguntas têm naturezas estatísticas distintas e exigem, cada uma, uma família diferente de modelo linear generalizado (Nelder; Wedderburn, 1972; McCullagh; Nelder, 1989): a infestação pela broca é uma **contagem** sob esforço amostral variável; a severidade da ferrugem é uma **proporção contínua** sem denominador; e o padrão de exportação é uma resposta **binária**. Tratar as três com a mesma ferramenta seria ignorar o que a natureza de cada dado impõe. Portanto, cada pergunta se transformou em um desafio particular a ser tratado conforme suas especificidades.

Após a análise exploratória univariada¹, este relatório apresenta os três modelos, o processo de seleção de variáveis, o diagnóstico de resíduos e a recomendação de manejo decorrente.

0.1 Variáveis categóricas de manejo e produção

regiao_produtores: 99 talhões em Sul de Minas (moda), 92 em Cerrado Mineiro, 82 em Mogiana e 67 em Matas de Minas (Figura 1a).

cultivar: 118 talhões com Mundo Novo (moda), 106 com Catuaí, 62 com Icatu e 54 com Bourbon (Figura 1b).

manejo: 166 talhões em manejo convencional (moda), 122 em integrado e 52 em orgânico (Figura 1c).

irrigacao: predominam 202 talhões sem irrigação (moda) frente a 138 irrigados (Figura 1d).




Figura 1: Frequência absoluta das variáveis categóricas.

0.2 Variáveis quantitativas de solo, clima e manejo

altitude_m: variou de 496 a 1343 m ($\bar{x} = 937,1$ m e $s = 156,5$ m), com maior concentração entre 830 e 1046 m – faixa compatível com os 500–1200 m descritos para o parque cafeeiro de Minas Gerais (Bernardes *et al.*, 2012) (Figura 2).

¹ Acesse a análise exploratória completa no repositório do github do projeto.




Figura 2: Distribuição da altitude (m).

declividade_pct: variou de 1% a 51,4% ($\bar{x} = 19,9\%$ e $s = 8.43\%$), com predomínio de terrenos forte-ondulados inpe2023declividade; esse resultado diverge da faixa de 5% a 15% (Bernardes *et al.*, 2012) para a região (Figura 3).




Figura 3: Distribuição da declividade (%). Predomínio de terrenos forte-ondulados.

idade_lavoura_anos: variou de 1 a 31,1 anos ($\bar{x} = 9,25$ anos e $s = 4.95$ anos), com predomínio de lavoura adulta a partir de dois anos (Nascimento *et al.*, 2019), embora a maioria dos talhões seja mais jovem que os 10 a 30 anos de permanência típicos (Silva; Salvador; Pádua, 2000) (Figura 4).




Figura 4: Distribuição da idade da lavoura (anos).

densidade_plantio: predomínio do sistema semi-adensado (302 talhões), seguido de tradicional (26) e adensado (12), conforme os limiares de classificação (Malta *et al.*, 2005)

(Figura 5).




Figura 5: Talhões por classe de densidade de plantio. Predomínio semi-adensado.

adubacao_n_kg_ha: variou de 40 a 532 kg/ha ($\bar{x} = 315,8$ kg/ha e $s = 89.39$ kg/ha), com distribuição aproximadamente bimodal; 50% dos talhões receberam entre 257 e 384 kg/ha (Figura 6).




Figura 6: Distribuição da adubação nitrogenada (kg/ha).

precipitacao_safra_mm: variou de 833 a 2208 mm, com $\bar{x}$ de 1450 mm e s de 246,3 mm (Figura 7).




Figura 7: Distribuição da precipitação na safra (mm).

umidade_relativa_pct: variou de 49,4% a 92,2%, com $\bar{x}$ de 74,0% e s de 6.65% (Figura 8).




Figura 8: Distribuição da umidade relativa (%). Média = 74,0%.

ph_solo: variou de 4,28 a 6,66 ($\bar{x} = 5,43$ e $s = 0.44$), caracterizando acidez média e posicionando os solos no limite superior da classe de qualidade baixa segundo os critérios agrônômicos (Mesquita *et al.*, 2016) (Figura 9).




Figura 9: Distribuição do pH do solo, por classe.

materia_organica_pct: variou de 0,80% a 5,04% ($\bar{x} = 2,75\%$ e $s = 0.78\%$), enquadrando-se na classe de fertilidade média (Mesquita *et al.*, 2016) (Figura 10).




Figura 10: Distribuição da matéria orgânica (%), por classe.

0.3 Variáveis de monitoramento da broca-do-café

n_armadilhas: variou de 4 a 12 armadilhas por talhão; moda e mediana iguais a 8 (Figura 11a).

dias_exposicao: concentrou-se em três valores – 15, 20 e 30 dias –, sendo 15 dias o mais frequente (140 talhões) (Figura 11b).

n_brocas_capturadas: variou de 0 a 62 brocas; moda de 4 e mediana de 6, com distribuição assimétrica à direita (Figura 11c).




Figura 11: Frequência absoluta – monitoramento da broca-do-café.

1 Materiais e métodos

1.1 Base de dados

Os 340 talhões trazem, além das covariáveis agronômicas, três desfechos distintos: `n_brocas_capturadas`, `severidade_ferrugem` e `padrao_exportacao`. Essa estrutura exige cuidado: **cada desfecho é variável resposta em um desafio e candidato a preditor nos demais**, e nem toda inclusão é legítima. A questão reaparece explicitamente na Seção 4.2.

Há ainda duas variáveis que descrevem o *processo de medição*, não o talhão: `n_armadilhas` e `dias_exposicao`. O produto das duas define o esforço amostral, que varia de 60 a 360 unidades — uma amplitude de 6 vezes. Comparar contagens brutas entre talhões seria, portanto, comparar coisas diferentes.

1.2 Procedimentos comuns

Todos os ajustes foram feitos em R (R: . . . , 2026), com scripts reproduíveis e semente fixada. Três procedimentos são comuns aos três desafios:

1. **Seleção de variáveis** por teste da razão de verossimilhanças, partindo do modelo amplo, com exclusão prévia das variáveis irrelevantes por construção e verificação de multicolinearidade pelo fator de inflação da variância.
2. **Diagnóstico** por resíduos quantílicos aleatorizados (Dunn; Smyth, 1996), envelope simulado (Atkinson, 1981), verificação de dispersão, identificação de pontos influentes e exame da linearidade das covariáveis contínuas na escala do preditor linear.

3. **Interpretação na escala original** do fenômeno — brocas por unidade de esforço, pontos percentuais de severidade e probabilidade de exportação —, e não apenas na escala do preditor linear.

2 Desafio A — infestação pela broca

A análise teve como objetivo identificar quais condições de talhão favorecem a infestação pela broca-do-café e quantificar o efeito de cada uma dessas condições sobre a pressão de praga, medida pelo número de brocas capturadas ($n_brocas_capturadas$). Inicialmente, foi realizada uma análise exploratória multivariada, avaliando as associações da variável resposta com as nove variáveis candidatas por meio dos coeficientes de correlação de Pearson, Kendall e Spearman, complementados por uma matriz de correlação global com teste de significância (Figura 12). Essa etapa exploratória indicou uma associação moderada e positiva entre o número de brocas capturadas e a umidade relativa (0.36), além de associações fracas, mas significativas, com as demais variáveis, exceto declividade, idade da lavoura e ph do solo, orientando a construção de uma sequência de modelos: partindo de um modelo nulo (mod00), avançando para modelos completos com todas as covariáveis (mod01 a mod04), testando-se a incorporação do esforço amostral, e culminando em modelos de seleção de variáveis via critério de informação de Akaike (AICc) e em modelos finais mais parcimoniosos, tanto sob a distribuição Poisson (mod05 e mod06) quanto, posteriormente, sob a distribuição binomial negativa (mod07 a mod10), em razão da superdispersão identificada nos dados.




Figura 12: Matriz de correlação global com teste de significância entre a variável resposta ($n_brocas_capturadas$) e as variáveis candidatas.

2.1 O esforço amostral e o *offset*

A contagem de brocas depende de quantas armadilhas foram instaladas e por quantos dias. Um talhão com esforço seis vezes maior tende a capturar mais insetos sem que a in-

festação seja maior. Como o número de brocas capturadas depende também do esforço de amostragem empregado em cada talhão, essa medida foi incorporada aos modelos de duas formas alternativas: como termo de *offset* (coeficiente fixado em 1, na escala logarítmica) e como preditor livre (com coeficiente estimado livremente). O modelo nulo com o esforço amostral como *offset* (mod02) e o modelo completo correspondente (mod03) reduziram a deviança nula em 36,22%, contra uma redução de 29,84% observada no modelo completo sem essa medida (mod01), evidenciando um ganho de 6,38 pontos percentuais na capacidade explicativa ao se considerar o esforço amostral. Em seguida, ajustou-se um modelo com o esforço amostral como preditor livre (mod04), cujo coeficiente estimado (0,901) mostrou-se muito próximo de 1, sustentando a adequação de se fixar esse coeficiente em 1 por meio de um termo de *offset*. Essa adequação caracteriza um modelo de taxa em que a contagem de brocas continua sendo modelada como variável resposta de um modelo Poisson, sem a necessidade de estimar um parâmetro adicional para o esforço amostral (Faraway, 2006). Portanto, com um modelo de taxa, a quantidade de interesse é a taxa de captura por unidade de esforço, μ/E , e não a contagem:


$$\log\left(\frac{\mu_i}{E_i}\right) = \mathbf{x}_i' \boldsymbol{\beta} \iff \log(\mu_i) = \log(E_i) + \mathbf{x}_i' \boldsymbol{\beta}, \quad (1)$$

com $E_i = \text{n_armadilhas}_i \times \text{dias_exposicao}_i$. O termo $\log(E_i)$ entra com coeficiente fixado em 1 — é um *offset*, não um preditor, e por isso não consome graus de liberdade.


A partir do modelo completo com o esforço amostral como *offset* (mod03), foram ajustados iterativamente todos os subconjuntos possíveis de covariáveis (*dredge*), e o modelo de menor AICc (mod05) coincidiu com o próprio modelo completo (mod03), mantendo as nove covariáveis. Como declividade e pH do solo não apresentaram efeito estatisticamente significativo em mod05, ajustou-se um modelo final apenas com as seis variáveis de efeito significativo — adubação, altitude, densidade de plantio, idade da lavoura, matéria orgânica e umidade relativa —, denominado mod06. Embora a redução da deviança nula de mod06 (35,96%) tenha sido ligeiramente inferior à de mod05 (36,22%), o modelo mod06 apresentou AICc menor (2261,2 contra 2263,1), sendo por isso preferido como modelo Poisson mais parcimonioso.

2.2 Da Poisson à binomial negativa


A Poisson impõe $\text{Var}[y] = \mathbb{E}[y]$ enquanto que a binomial negativa admite $\text{Var}[y] = \mu + \mu^2/\theta$ (Faraway, 2006). O diagnóstico de equidispersão revelou que a razão entre variância e média das contagens brutas foi de 3,51. Os testes formais (*dispersiontest*) confirmaram superdispersão tanto sob a hipótese de variância linear ($\alpha = 2,08$; $p < 0,001$) quanto quadrática ($\alpha = 0,20$; $p < 0,001$), e o parâmetro de dispersão de Pearson estimado para mod06 (3,17) foi superior a 1.




(a) Frequências observadas vs. esperadas – Poisson



(b) Resíduos – Poisson



(c) Frequências observadas vs. esperadas – Binomial Negativa



(d) Resíduos – Binomial Negativa

Figura 13: Comparação entre as frequências relativas observadas e esperadas do número de brocas capturadas, e respectivos resíduos, sob os modelos Poisson e Binomial Negativa.

Diante dessas evidências, e também da inspeção visual do desencaixe entre as frequências observadas e esperadas, bem como aumento de resíduos sob Poisson quando comparado à binomial negativa (Figura 13), optou-se por abandonar o primeiro e adotar o segundo para a modelagem da contagem de brocas capturadas.

2.3 Definição do modelo binomial negativo final (mod10) e análise de resíduos

Repetindo a mesma lógica de seleção de variáveis, o modelo binomial negativo completo com esforço amostral como offset (mod08) foi submetido ao procedimento de *dredge*, resultando em um modelo de AICc mínimo (mod09) com as mesmas nove covariáveis originais. Como declividade, pH do solo e precipitação da safra não apresentaram efeito estatisticamente significativo em mod09, ajustou-se um modelo final com adubação, altitude, densidade de plantio, idade da lavoura, matéria orgânica e umidade relativa —, denominado mod10. A Figura 14 ilustra os efeitos das variáveis nos modelos mod09 e mod10, respectivamente.




Figura 14: Efeitos das variáveis preditoras nos modelos mod09 e mod10.

Esse modelo apresentou AICc ligeiramente menor (1950,1) do que mod09 (1956,0), sendo então adotado como modelo final, com um teste de razão de verossimilhanças frente ao modelo nulo (mod07) altamente significativo ($LR = 133,39$; 6 g.l.; $p < 0,001$). O diagnóstico de resíduos de mod10 indicou, pelo gráfico meia-normal dos resíduos *rstudent*, a presença de valores atípicos na variável resposta, principalmente nas observações 213 e 287; pelo gráfico meia-normal dos valores de alavancagem (*leverage*), foram identificadas como atípicas, quanto à combinação de valores das variáveis preditoras (*leverage*), as observações 85 e 148, considerando o ponto de corte de alavancagem de 0,0353; e, pela distância de Cook, as observações 84 e 272 destacaram-se muito acima das demais, indicando influência global relevante dessas observações sobre o ajuste do modelo. A Figura 15 ilustra os diagnósticos de resíduos.




Figura 15: Gráficos meia-normal de diagnóstico de resíduos para o modelo binomial negativa final (mod10).

2.4 Parecer

As razões de taxa (*rate ratios*) apresentadas a seguir foram obtidas pela exponenciação dos coeficientes estimados do modelo binomial negativa final (mod10),

$$RT_j = e^{\hat{\beta}_j}, \quad (2)$$

de modo que cada razão de taxa expressa o fator multiplicativo pelo qual a taxa esperada de captura de brocas se altera a cada aumento de uma unidade na respectiva variável preditora j , mantendo as demais covariáveis e o esforço amostral constantes. Valores de RT_j acima de 1 indicam aumento percentual na pressão de praga, enquanto valores abaixo de 1 indicam redução, sendo a magnitude desse efeito percentual calculada como

$$\Delta\%_j = (RT_j - 1) \times 100\%. \quad (3)$$

Portanto, as condições de talhão que favorecem a infestação pela broca e o quanto se ganha ou se perde em pressão de praga ao alterar cada uma delas, mantendo as demais variáveis e o esforço amostral constantes, são:

- **Adubação nitrogenada:** cada aumento de 1 kg/ha reduz a pressão de praga em aproximadamente 0,08% (razão de taxa = 0,9992). Ou seja, a adubação nitrogenada atua como fator de proteção, e não de risco.
- **Altitude:** cada aumento de 1 metro reduz a taxa de captura em aproximadamente 0,11% (razão de taxa = 0,9989). Talhões em altitudes maiores tendem a apresentar menor pressão de praga.
- **Densidade de plantio:** cada planta adicional por hectare aumenta a pressão de praga em aproximadamente 0,02% (razão de taxa = 1,0002). O efeito é estatisticamente significativo, porém de magnitude muito pequena por unidade.
- **Idade da lavoura:** cada ano adicional de idade aumenta a pressão de praga em aproximadamente 1,73% (razão de taxa = 1,0173).
- **Matéria orgânica do solo:** cada aumento de 1 ponto percentual de matéria orgânica aumenta a pressão de praga em aproximadamente 14,04% (razão de taxa = 1,1403). Este é um dos efeitos de maior magnitude entre os preditores significativos.
- **Umidade relativa:** cada aumento de 1 ponto percentual de umidade aumenta a pressão de praga em aproximadamente 5,00% (razão de taxa = 1,0497), consistente com a associação moderada e positiva identificada na análise exploratória.
- **Declividade, pH do solo e precipitação da safra** não apresentaram efeito estatisticamente significativo sobre a taxa de captura (intervalos de confiança de 95% contendo o valor 1).

Em síntese, matéria orgânica e umidade relativa são as condições de talhão que mais favorecem a infestação pela broca, enquanto adubação nitrogenada e altitude atuam como fatores de proteção. Densidade de plantio e idade da lavoura apresentam efeitos positivos, porém de magnitude reduzida.

3 Desafio B — severidade da ferrugem

3.1 Por que não binomial nem regressão linear

A severidade foi medida como fração de área foliar comprometida por análise de imagem. **Não existe denominador:** não se contaram folhas lesionadas de um total de N . Os 340 valores ocupam 320 níveis distintos no intervalo $[0,0010; 0,6098]$, sem nenhuma observação exata em 0 ou 1 (0 e 0, respectivamente).

Forçar a família binomial exigiria *inventar* um n . Como a variância binomial é $\mu(1 - \mu)/n$, essa escolha arbitrária propaga-se para toda a inferência: variando o n inventado entre 20 e 2000, o erro-padrão do coeficiente da cultivar varia cerca de dez vezes, sem que dado algum mude. Correções por quase-verossimilhança ou erros-padrão robustos eliminam essa dependência, mas ao custo de abandonar a verossimilhança — e com ela o teste de razão de verossimilhanças que a análise de dispersão exige.

A regressão linear, por sua vez, produz previsões negativas e supõe variância constante, quando a variância de uma proporção é estruturalmente função da média: não há espaço para variar perto dos limites do intervalo.

3.2 Regressão beta

Adotou-se a regressão beta na parametrização de Ferrari e Cribari-Neto (2004), implementada por Cribari-Neto e Zeileis (2010), em que $\mathbb{E}[y] = \mu$ e

$$\text{Var}[y] = \frac{\mu(1 - \mu)}{1 + \phi}, \quad (4)$$

com ϕ interpretado como *precisão*: quanto maior, mais concentrada a distribuição em torno de μ . A variância depende da média por construção, e o problema estrutural do modelo linear desaparece.

A ligação foi escolhida por critério explícito, e não por ser o padrão do pacote. Comparadas as seis ligações disponíveis, 4 ficam dentro de $\Delta\text{AIC} < 2$ e os dados não as distinguem; a diferença estimada entre cultivares permanece entre 11,0 e 12,9 pontos percentuais qualquer que seja a escolha. A `cauchit` foi eliminada por ajuste (ΔAIC 18,17) e a `log` por garantir apenas o limite inferior do intervalo. Entre as restantes, adotou-se a `logit` por ser a única cujos coeficientes exponenciados correspondem a razões de chances.




Figura 16: Faixa de predições das três abordagens contra o domínio válido da severidade. O modelo linear invade a região impossível abaixo de zero; a regressão beta não pode sair do intervalo, por construção.

3.3 Dispersão constante

O enunciado pede que se investigue se ϕ é constante. Ajustou-se um modelo com preditor também para a precisão e comparou-se por razão de verossimilhanças. Nenhuma covariável, isolada ou em conjunto, rejeitou a constância: para a cultivar, $LR = 3,344$ com $p = 0,342$.

A sustentação positiva vem do exame direto dos resíduos padronizados: ao longo de cinco faixas do valor ajustado, a média varia 4,5 vezes e a variância bruta 4,7 vezes, enquanto o desvio dos resíduos varia apenas 1,210 vezes, sem que os testes de Bartlett ($p = 0,543$) ou de Brown-Forsythe ($p = 0,552$) acusem heterogeneidade. Adotou-se, portanto, ϕ constante, estimado em 20,20.

Registre-se o alcance dessa conclusão: o intervalo de confiança das razões de ϕ entre cultivares vai de 0,57 a 2,31. Descarta-se variação ampla de precisão, não qualquer variação.

3.4 Seleção e efeitos

A seleção *backward* por razão de verossimilhanças reduziu o modelo de 19 para 10 parâmetros, com melhora simultânea de AIC ($-879,47 \rightarrow -889,18$) e BIC ($-802,89 \rightarrow -847,06$). O modelo final alcança pseudo- R^2 de 0,4980.

Tabela 1: Efeito da cultivar sobre a severidade da ferrugem, em razões de chances, tomando a Bourbon como referência.

Cultivar	Coefficiente	Razão de chances	IC 95%
Catuaí	-0,5136	0,5983	[0,4987; 0,7178]
Icatu	-1,2805	0,2779	[0,2200; 0,3510]
Mundo Novo	-0,3093	0,7339	[0,6167; 0,8734]

Como a ligação `logit` é não linear, o efeito em pontos percentuais depende do nível das demais covariáveis. Num talhão típico — umidade e densidade nas medianas —, a severidade esperada é 20,80% para a Bourbon contra 6,82% para a Icatu, uma diferença de 13,97 pontos percentuais. Sob condições favoráveis à doença essa diferença sobe a 22,0 pontos; sob condições desfavoráveis, cai a 8,0.

Gráfico Meio-Normal com Envelope Simulado

Como esperado de uma banda de 95%, ~5% dos pontos caem fora; nenhum desvio sistemático




Figura 17: Gráfico meio-normal com envelope simulado por 99 reajustes do próprio modelo. A proporção de pontos fora da banda é compatível com o esperado para um envelope de 95%, sem fugas sistemáticas nas caudas.

4 Desafio C — padrão de exportação

[PENDENTE: Seção preliminar. O modelo logístico final ainda não foi ajustado; ver o plano de implementação. Os números abaixo são descritivos e de mediação, já extraídos da base.]

4.1 A resposta

Dos 340 talhões, 160 atingem o padrão de exportação e 180 não, o que corresponde a uma prevalência de 47,06%. A resposta é, portanto, **balanceada** — fato que importa para a Seção 4.3, porque desloca a discussão do ponto de corte do desbalanceamento para o custo assimétrico dos erros.

A classe minoritária com 160 casos admite, pela regra de dez eventos por variável (Peduzzi *et al.*, 1996), cerca de 16 parâmetros. O modelo amplo com a severidade excede esse limite, o que torna a seleção de variáveis uma necessidade, e não uma preferência estética.

4.2 Efeito total e efeito direto da cultivar

A `severidade_ferrugem` é ela própria um desfecho, influenciada pela cultivar. Incluí-la como preditor da exportação muda o que o coeficiente da cultivar significa (Pearl, 2009; VanderWeele, 2016).

Os dados revelam uma configuração instrutiva: a cultivar Icatu apresenta *a menor* severidade média e, simultaneamente, *a menor* taxa de exportação. Os dois caminhos causais operam em direções opostas.

Tabela 2: Coeficientes da cultivar na predição da exportação, com e sem a severidade no modelo. Referência: Bourbon.

Cultivar	Efeito total (sem severidade)	Efeito direto (com severidade)
Catuaí	0,0028	-0,2543
Icatu	-0,6080	-1,1488
Mundo Novo	-0,4559	-0,6403

No modelo que inclui a severidade, o coeficiente desta é -3,6833 ($p = 0,002$): a ferrugem de fato reduz a chance de exportação. A Icatu adoece menos, o que a beneficia por esse caminho; mas seu coeficiente direto é -1,1488, contra -0,6080 no efeito total. A penalidade direta é parcialmente compensada pelo ganho via menor doença.

Qual deles responde à pergunta do produtor? O produtor escolhe a cultivar *antes do plantio* e herda os dois caminhos — o direto e o mediado pela ferrugem. O **efeito total** é, portanto, o que responde à sua pergunta. O efeito direto responde a outra, também legítima: quanto restaria da cultivar se a ferrugem fosse controlada por outro meio.

Cabe a ressalva: a leitura causal dessa decomposição pressupõe ausência de confundidor não medido entre ferrugem e exportação — hipótese que **não é testável** com estes

dados.

4.3 Capacidade preditiva e ponto de corte

[PENDENTE: Matriz de confusão, curva ROC, AUC com intervalo de DeLong (DeLong; DeLong; Clarke-Pearson, 1988), validação cruzada com seleção dentro do *fold*, calibração e escolha do ponto de corte por custo assimétrico.]

5 Decisão e recomendação de manejo

[PENDENTE: Consolidar após o fechamento dos Desafios A e C. A recomendação deve quantificar os efeitos na escala original: brocas por unidade de esforço, pontos percentuais de severidade e probabilidade de exportação.]

A escolha da cultivar é o fator de maior impacto sobre a ferrugem: 13,97 pontos percentuais de severidade separam a Bourbon da Icatu num talhão típico. Essa vantagem, contudo, não se traduz automaticamente em exportação — a Seção 4.2 mostra que a Icatu carrega uma penalidade direta que compensa parte do ganho fitossanitário. A recomendação de cultivar, portanto, não pode ser derivada apenas do Desafio B.

6 Considerações finais

[PENDENTE: Redigir ao final.]

Referências

ATKINSON, Anthony C. Two Graphical Displays for Outlying and Influential Observations in Regression. **Biometrika**, v. 68, n. 1, p. 13–20, 1981. DOI: 10.1093/biomet/68.1.13.

BERNARDES, Tiago *et al.* Diagnóstico físico-ambiental da cafeicultura no Estado de Minas Gerais – Brasil. **Coffee Science**, v. 7, p. 139–151, 2012.

CRIBARI-NETO, Francisco; ZEILEIS, Achim. Beta Regression in R. **Journal of Statistical Software**, v. 34, n. 2, p. 1–24, 2010. DOI: 10.18637/jss.v034.i02.

DELONG, Elizabeth R.; DELONG, David M.; CLARKE-PEARSON, Daniel L. Comparing the Areas under Two or More Correlated Receiver Operating Characteristic Curves: A Nonparametric Approach. **Biometrics**, v. 44, n. 3, p. 837–845, 1988. DOI: 10.2307/2531595.

DUNN, Peter K.; SMYTH, Gordon K. Randomized Quantile Residuals. **Journal of Computational and Graphical Statistics**, v. 5, n. 3, p. 236–244, 1996. DOI: 10.1080/10618600.1996.10474708.

FARAWAY, Julian J. **Extending the Linear Model with R: Generalized Linear, Mixed Effects and Nonparametric Regression Models**. Boca Raton, FL: Chapman & Hall/CRC, 2006. (Texts in Statistical Science). ISBN 978-1-58488-424-8.

FERRARI, Silvia L. P.; CRIBARI-NETO, Francisco. Beta Regression for Modelling Rates and Proportions. **Journal of Applied Statistics**, v. 31, n. 7, p. 799–815, 2004. DOI: 10.1080/0266476042000214501.

MALTA, Marcelo R. *et al.* Caracterização agronômica de lavouras cafeeiras cultivadas sob o sistema orgânico no sul de Minas Gerais. **Congresso Brasileiro de Pesquisas Cafeeiras**, p. 399–400, 2005.

MCCULLAGH, Peter; NELDER, John A. **Generalized Linear Models**. 2. ed. London: Chapman e Hall, 1989.

MESQUITA, Carlos Magno de *et al.* **Manual do Café: Manejo de Cafezais em Produção**. [S. l.: s. n.], 2016. p. 1–72.

NASCIMENTO, Jefferson Luiz Marciano do *et al.* Tolerância de plantas jovens de café a herbicidas aplicados isoladamente ou em mistura com o fertilizante Fertiactyl. **Weed Control Journal**, v. 18, 2019. DOI: 10.7824/rbh.v18i4.681.

NELDER, John A.; WEDDERBURN, Robert W. M. Generalized Linear Models. **Journal of the Royal Statistical Society: Series A (General)**, v. 135, n. 3, p. 370–384, 1972. DOI: 10.2307/2344614.

PEARL, Judea. **Causality: Models, Reasoning, and Inference**. 2. ed. Cambridge: Cambridge University Press, 2009.

PEDUZZI, Peter *et al.* A Simulation Study of the Number of Events per Variable in Logistic Regression Analysis. **Journal of Clinical Epidemiology**, v. 49, n. 12, p. 1373–1379, 1996. DOI: 10.1016/S0895-4356(96)00236-3.

R CORE TEAM. **R: A Language and Environment for Statistical Computing**. Vienna, Austria, 2026. Disponível em: <https://www.R-project.org/>.

SANTOS, Vladimir Faria dos *et al.* Análise da eficiência técnica de talhões de café irrigados e não-irrigados em Minas Gerais: 2004-2006. **Revista de Economia e Sociologia Rural**, v. 47, p. 677–698, 2009. DOI: 10.1590/S0103-20032009000300007.

SILVA, Fábio Moreira da; SALVADOR, Nilson; PÁDUA, Tassiana de Souza. Café: mecanização da colheita. *In*: I Simpósio de Pesquisa dos Cafés do Brasil. [*S. l.: s. n.*], 2000. p. 281–329.

VANDERWEELE, Tyler J. Mediation Analysis: A Practitioner's Guide. **Annual Review of Public Health**, v. 37, p. 17–32, 2016. DOI: 10.1146/annurev-publhealth-032315-021402.