

UNIVERSIDADE DO VALE DO ITAJAÍ — UNIVALI

Escola Politécnica

Programa de Pós-Graduação em Computação Aplicada — PPGCA

Disciplina: Modelagem Estatística

Prof. Dr. Rodrigo Sant’Ana

Modelos Lineares Generalizados aplicados ao manejo fitossanitário da cafeicultura

Grupo 2 — Broca, ferrugem e padrão de exportação

Matheus Piotroski Neis · Letícia Zorzi Rama · André Ribeiro

Itajaí, Santa Catarina — Setembro de 2026

1 Introdução

A cooperativa precisa decidir onde concentrar o esforço de manejo na próxima safra e que recomendações fazer aos cooperados quanto a cultivar, densidade de plantio, adubação e irrigação. O conjunto de dados reúne 340 talhões de café descritos por 19 variáveis agronômicas, climáticas e fitossanitárias.

As três perguntas do corpo técnico têm naturezas estatísticas distintas e exigem, cada uma, uma família diferente de modelo linear generalizado (Nelder; Wedderburn, 1972; McCullagh; Nelder, 1989): a infestação pela broca é uma **contagem** sob esforço amostral variável; a severidade da ferrugem é uma **proporção contínua** sem denominador; e o padrão de exportação é uma resposta **binária**. Tratar as três com a mesma ferramenta seria ignorar o que a natureza de cada dado impõe.

Este relatório apresenta os três modelos, o processo de seleção de variáveis, o diagnóstico de resíduos e a recomendação de manejo decorrente.

2 Materiais e métodos

2.1 Base de dados

Os 340 talhões trazem, além das covariáveis agronômicas, três desfechos distintos: `n_brocas_capturadas`, `severidade_ferrugem` e `padrao_exportacao`. Essa estrutura exige cuidado: **cada desfecho é variável resposta em um desafio e candidato a**

preditor nos demais, e nem toda inclusão é legítima. A questão reaparece explicitamente na Seção 5.2.

Há ainda duas variáveis que descrevem o *processo de medição*, não o talhão: `n_armadilhas` e `dias_exposicao`. O produto das duas define o esforço amostral, que varia de 60 a 360 unidades — uma amplitude de 6 vezes. Comparar contagens brutas entre talhões seria, portanto, comparar coisas diferentes.

2.2 Procedimentos comuns

Todos os ajustes foram feitos em R (R: . . . , 2026), com scripts reprodutíveis e semente fixada. Três procedimentos são comuns aos três desafios:

1. **Seleção de variáveis** por teste da razão de verossimilhanças, partindo do modelo amplo, com exclusão prévia das variáveis irrelevantes por construção e verificação de multicolinearidade pelo fator de inflação da variância.
2. **Diagnóstico** por resíduos quantílicos aleatorizados (Dunn; Smyth, 1996), envelope simulado (Atkinson, 1981), verificação de dispersão, identificação de pontos influentes e exame da linearidade das covariáveis contínuas na escala do preditor linear.
3. **Interpretação na escala original** do fenômeno — brocas por unidade de esforço, pontos percentuais de severidade e probabilidade de exportação —, e não apenas na escala do preditor linear.

3 Desafio A — infestação pela broca

[PENDENTE: Seção em consolidação: o modelo final da equipe ainda está sendo revisado. Os números abaixo já vêm das macros e se atualizam sozinhos.]

3.1 O esforço amostral e o *offset*

A contagem de brocas depende de quantas armadilhas foram instaladas e por quantos dias. Um talhão com esforço seis vezes maior tende a capturar mais insetos sem que a infestação seja maior. A quantidade de interesse é a *taxa* de captura por unidade de esforço, μ/E , e não a contagem:

$$\log\left(\frac{\mu_i}{E_i}\right) = \mathbf{x}_i' \boldsymbol{\beta} \iff \log(\mu_i) = \log(E_i) + \mathbf{x}_i' \boldsymbol{\beta}, \quad (1)$$

com $E_i = \text{n_armadilhas}_i \times \text{dias_exposicao}_i$. O termo $\log(E_i)$ entra com coeficiente fixado em 1 — é um *offset*, não um preditor, e por isso não consome grau de liberdade.

Essa fixação é uma hipótese testável. Deixando o coeficiente livre, obtém-se $\hat{\gamma} = 0,898$, com intervalo de confiança de 95% $[0,816; 0,980]$, que não contém o valor 1.

[PENDENTE: O intervalo não contém 1 sob a especificação apenas com covariáveis numéricas. Com os fatores categóricos no modelo, passa a conter. A equipe precisa decidir qual especificação reportar e justificar a fixação do *offset* à luz disso — ou assumir explicitamente a proporcionalidade como hipótese de trabalho.]

3.2 Da Poisson à binomial negativa

A Poisson impõe $\text{Var}[y] = \mathbb{E}[y]$. A razão entre a estatística de Pearson e os graus de liberdade foi 3,174, muito acima de 1, e o teste de Cameron e Trivedi (1990) rejeita a equidispersão ($p = < 0,001$). A variância excede a média, e ignorar isso subestima os erros-padrão.

Adotou-se então a binomial negativa (Hilbe, 2011), que acrescenta um parâmetro de forma θ e admite $\text{Var}[y] = \mu + \mu^2/\theta$. O ajuste resultou em $\hat{\theta} = 4,370$ (erro-padrão 0,542), e a razão de Pearson caiu para 1,085 — compatível com 1. O AIC passou de 2261,25 na Poisson para 1950,13 na binomial negativa.

3.3 Efeitos estimados

Com ligação logarítmica e *offset*, $\exp(\beta_j)$ lê-se como **razão de taxas** de captura por unidade de esforço. As estimativas do modelo final com 7 parâmetros indicam que a umidade relativa (razão de taxas 1,0498 por ponto percentual) e a matéria orgânica do solo (1,1404) elevam a infestação, enquanto a altitude a reduz (0,9989).

[PENDENTE: Diagnóstico de resíduos e figura do envelope simulado do Desafio A.]

4 Desafio B — severidade da ferrugem

4.1 Por que não binomial nem regressão linear

A severidade foi medida como fração de área foliar comprometida por análise de imagem. **Não existe denominador:** não se contaram folhas lesionadas de um total de N . Os 340 valores ocupam 320 níveis distintos no intervalo $[0,0010; 0,6098]$, sem nenhuma observação exata em 0 ou 1 (0 e 0, respectivamente).

Forçar a família binomial exigiria *inventar* um n . Como a variância binomial é $\mu(1 - \mu)/n$, essa escolha arbitrária propaga-se para toda a inferência: variando o n inventado entre 20 e 2000, o erro-padrão do coeficiente da cultivar varia cerca de dez vezes, sem que dado algum mude. Correções por quase-verossimilhança ou erros-padrão robustos eliminam essa dependência, mas ao custo de abandonar a verossimilhança — e com ela o teste de razão de verossimilhanças que a análise de dispersão exige.

A regressão linear, por sua vez, produz previsões negativas e supõe variância constante, quando a variância de uma proporção é estruturalmente função da média: não há espaço para variar perto dos limites do intervalo.

4.2 Regressão beta

Adotou-se a regressão beta na parametrização de Ferrari e Cribari-Neto (2004), implementada por Cribari-Neto e Zeileis (2010), em que $\mathbb{E}[y] = \mu$ e

$$\text{Var}[y] = \frac{\mu(1 - \mu)}{1 + \phi}, \quad (2)$$

com ϕ interpretado como *precisão*: quanto maior, mais concentrada a distribuição em torno de μ . A variância depende da média por construção, e o problema estrutural do modelo linear desaparece.

A ligação foi escolhida por critério explícito, e não por ser o padrão do pacote. Comparadas as seis ligações disponíveis, 4 ficam dentro de $\Delta\text{AIC} < 2$ e os dados não as distinguem; a diferença estimada entre cultivares permanece entre 11,0 e 12,9 pontos percentuais qualquer que seja a escolha. A `cauchit` foi eliminada por ajuste (ΔAIC 18,17) e a `log` por garantir apenas o limite inferior do intervalo. Entre as restantes, adotou-se a `logit` por ser a única cujos coeficientes exponenciados correspondem a razões de chances.




Figura 1: Faixa de previsões das três abordagens contra o domínio válido da severidade. O modelo linear invade a região impossível abaixo de zero; a regressão beta não pode sair do intervalo, por construção.

4.3 Dispersão constante

O enunciado pede que se investigue se ϕ é constante. Ajustou-se um modelo com preditor também para a precisão e comparou-se por razão de verossimilhanças. Nenhuma covariável, isolada ou em conjunto, rejeitou a constância: para a cultivar, $LR = 3,344$ com $p = 0,342$.

A sustentação positiva vem do exame direto dos resíduos padronizados: ao longo de cinco faixas do valor ajustado, a média varia 4,5 vezes e a variância bruta 4,7 vezes, enquanto o desvio dos resíduos varia apenas 1,210 vezes, sem que os testes de Bartlett ($p = 0,543$) ou de Brown-Forsythe ($p = 0,552$) acusem heterogeneidade. Adotou-se, portanto, ϕ constante, estimado em 20,20.

Registre-se o alcance dessa conclusão: o intervalo de confiança das razões de ϕ entre cultivares vai de 0,57 a 2,31. Descarta-se variação ampla de precisão, não qualquer variação.

4.4 Seleção e efeitos

A seleção *backward* por razão de verossimilhanças reduziu o modelo de 19 para 10 parâmetros, com melhora simultânea de AIC ($-879,47 \rightarrow -889,18$) e BIC ($-802,89 \rightarrow -847,06$). O modelo final alcança pseudo- R^2 de 0,4980.

Tabela 1: Efeito da cultivar sobre a severidade da ferrugem, em razões de chances, tomando a Bourbon como referência.

Cultivar	Coeficiente	Razão de chances	IC 95%
Catuaí	-0,5136	0,5983	[0,4987; 0,7178]
Icatu	-1,2805	0,2779	[0,2200; 0,3510]
Mundo Novo	-0,3093	0,7339	[0,6167; 0,8734]

Como a ligação *logit* é não linear, o efeito em pontos percentuais depende do nível das demais covariáveis. Num talhão típico — umidade e densidade nas medianas —, a severidade esperada é 20,80% para a Bourbon contra 6,82% para a Icatu, uma diferença de 13,97 pontos percentuais. Sob condições favoráveis à doença essa diferença sobe a 22,0 pontos; sob condições desfavoráveis, cai a 8,0.

Gráfico Meio-Normal com Envelope Simulado

Como esperado de uma banda de 95%, ~5% dos pontos caem fora; nenhum desvio sistemático




Figura 2: Gráfico meio-normal com envelope simulado por 99 reajustes do próprio modelo. A proporção de pontos fora da banda é compatível com o esperado para um envelope de 95%, sem fugas sistemáticas nas caudas.

5 Desafio C — padrão de exportação

[PENDENTE: Seção preliminar. O modelo logístico final ainda não foi ajustado; ver o plano de implementação. Os números abaixo são descritivos e de mediação, já extraídos da base.]

5.1 A resposta

Dos 340 talhões, 160 atingem o padrão de exportação e 180 não, o que corresponde a uma prevalência de 47,06%. A resposta é, portanto, **balanceada** — fato que importa para a Seção 5.3, porque desloca a discussão do ponto de corte do desbalanceamento para o custo assimétrico dos erros.

A classe minoritária com 160 casos admite, pela regra de dez eventos por variável (Peduzzi *et al.*, 1996), cerca de 16 parâmetros. O modelo amplo com a severidade excede esse limite, o que torna a seleção de variáveis uma necessidade, e não uma preferência estética.

5.2 Efeito total e efeito direto da cultivar

A `severidade_ferrugem` é ela própria um desfecho, influenciada pela cultivar. Incluí-la como preditor da exportação muda o que o coeficiente da cultivar significa (Pearl, 2009; VanderWeele, 2016).

Os dados revelam uma configuração instrutiva: a cultivar Icatu apresenta *a menor* severidade média e, simultaneamente, *a menor* taxa de exportação. Os dois caminhos causais operam em direções opostas.

Tabela 2: Coeficientes da cultivar na predição da exportação, com e sem a severidade no modelo. Referência: Bourbon.

Cultivar	Efeito total (sem severidade)	Efeito direto (com severidade)
Catuaí	0,0028	-0,2543
Icatu	-0,6080	-1,1488
Mundo Novo	-0,4559	-0,6403

No modelo que inclui a severidade, o coeficiente desta é -3,6833 ($p = 0,002$): a ferrugem de fato reduz a chance de exportação. A Icatu adoece menos, o que a beneficia por esse caminho; mas seu coeficiente direto é -1,1488, contra -0,6080 no efeito total. A penalidade direta é parcialmente compensada pelo ganho via menor doença.

Qual deles responde à pergunta do produtor? O produtor escolhe a cultivar *antes do plantio* e herda os dois caminhos — o direto e o mediado pela ferrugem. O **efeito total** é, portanto, o que responde à sua pergunta. O efeito direto responde a outra, também legítima: quanto restaria da cultivar se a ferrugem fosse controlada por outro meio.

Cabe a ressalva: a leitura causal dessa decomposição pressupõe ausência de confundidor não medido entre ferrugem e exportação — hipótese que **não é testável** com estes dados.

5.3 Capacidade preditiva e ponto de corte

[PENDENTE: Matriz de confusão, curva ROC, AUC com intervalo de DeLong (DeLong; DeLong; Clarke-Pearson, 1988), validação cruzada com seleção dentro do *fold*, calibração e escolha do ponto de corte por custo assimétrico.]

6 Decisão e recomendação de manejo

[PENDENTE: Consolidar após o fechamento dos Desafios A e C. A recomendação deve quantificar os efeitos na escala original: brocas por unidade de esforço, pontos percentuais de severidade e probabilidade de exportação.]

A escolha da cultivar é o fator de maior impacto sobre a ferrugem: 13,97 pontos percentuais de severidade separam a Bourbon da Icatu num talhão típico. Essa vantagem, contudo, não se traduz automaticamente em exportação — a Seção 5.2 mostra que a Icatu carrega uma penalidade direta que compensa parte do ganho fitossanitário. A recomendação de cultivar, portanto, não pode ser derivada apenas do Desafio B.

7 Considerações finais

[PENDENTE: Redigir ao final.]

Referências

ATKINSON, Anthony C. Two Graphical Displays for Outlying and Influential Observations in Regression. **Biometrika**, v. 68, n. 1, p. 13–20, 1981. DOI: 10.1093/biomet/68.1.13.

CAMERON, A. Colin; TRIVEDI, Pravin K. Regression-Based Tests for Overdispersion in the Poisson Model. **Journal of Econometrics**, v. 46, n. 3, p. 347–364, 1990. DOI: 10.1016/0304-4076(90)90014-K.

CRIBARI-NETO, Francisco; ZEILEIS, Achim. Beta Regression in R. **Journal of Statistical Software**, v. 34, n. 2, p. 1–24, 2010. DOI: 10.18637/jss.v034.i02.

DELONG, Elizabeth R.; DELONG, David M.; CLARKE-PEARSON, Daniel L. Comparing the Areas under Two or More Correlated Receiver Operating Characteristic Curves: A Nonparametric Approach. **Biometrics**, v. 44, n. 3, p. 837–845, 1988. DOI: 10.2307/2531595.

DUNN, Peter K.; SMYTH, Gordon K. Randomized Quantile Residuals. **Journal of Computational and Graphical Statistics**, v. 5, n. 3, p. 236–244, 1996. DOI: 10.1080/10618600.1996.10474708.

FERRARI, Silvia L. P.; CRIBARI-NETO, Francisco. Beta Regression for Modelling Rates and Proportions. **Journal of Applied Statistics**, v. 31, n. 7, p. 799–815, 2004. DOI: 10.1080/0266476042000214501.

HILBE, Joseph M. **Negative Binomial Regression**. 2. ed. Cambridge: Cambridge University Press, 2011.

MCCULLAGH, Peter; NELDER, John A. **Generalized Linear Models**. 2. ed. London: Chapman e Hall, 1989.

NELDER, John A.; WEDDERBURN, Robert W. M. Generalized Linear Models. **Journal of the Royal Statistical Society: Series A (General)**, v. 135, n. 3, p. 370–384, 1972. DOI: 10.2307/2344614.

PEARL, Judea. **Causality: Models, Reasoning, and Inference**. 2. ed. Cambridge: Cambridge University Press, 2009.

PEDUZZI, Peter *et al.* A Simulation Study of the Number of Events per Variable in Logistic Regression Analysis. **Journal of Clinical Epidemiology**, v. 49, n. 12, p. 1373–1379, 1996. DOI: 10.1016/S0895-4356(96)00236-3.

R CORE TEAM. **R: A Language and Environment for Statistical Computing**. Vienna, Austria, 2026. Disponível em: <https://www.R-project.org/>.

VANDERWEELE, Tyler J. Mediation Analysis: A Practitioner’s Guide. **Annual Review of Public Health**, v. 37, p. 17–32, 2016. DOI: 10.1146/annurev-publhealth-032315-021402.