

UNIVERSIDADE DO VALE DO ITAJAÍ — UNIVALI

Escola Politécnica

Programa de Pós-Graduação em Computação Aplicada — PPGCA

Mestrado em Computação Aplicada — MCA

Disciplina: Modelagem Estatística

Prof. Dr. Rodrigo Sant'Ana

Modelos Lineares Generalizados aplicados ao manejo fitossanitário da cafeicultura

Grupo 2 — Broca, ferrugem e padrão de exportação

André Ribeiro · Leticia Zorzi Rama · Matheus Piotroski Neis

Itajaí, Santa Catarina — Setembro de 2026

1 Contextualização

Uma cooperativa de cafeicultores de Minas Gerais enfrenta três problemas simultâneos que consomem seu orçamento técnico e definem sua margem:

- a **broca-do-café** (*Hypothenemus hampei*), monitorada por armadilhas instaladas em cada talhão;
- a **ferrugem alaranjada** (*Hemileia vastatrix*), avaliada pela severidade — a fração da área foliar lesionada;
- a **classificação do lote** para o mercado de exportação, que define o preço recebido.

O corpo técnico precisa decidir onde concentrar o esforço de manejo na próxima safra e que recomendações fazer aos cooperados quanto a cultivar, densidade de plantio, adubação e irrigação. O conjunto de dados reúne 340 talhões de café descritos por 19 variáveis agronômicas, climáticas e fitossanitárias. O talhão refere-se a determinada área da lavoura cafeeira que pode ser considerada homogênea, por ter a mesma variedade de café plantada na mesma data, em um solo de características físicas, químicas e topográficas semelhantes, além de receber o mesmo manejo agrônomico e o mesmo tratamento administrativo (Santos *et al.*, 2009).

Três perguntas foram formuladas com base nos problemas:

- Quais condições de talhão favorecem a infestação pela broca, e quanto se ganha em pressão de praga ao alterar cada uma delas?

- Que fatores agronômicos determinam a severidade da ferrugem, e existe uma cultivar comprovadamente mais resistente?
- O que determina a chance de um lote atingir o padrão de exportação?

Tais perguntas têm naturezas estatísticas distintas e exigem, cada uma, uma família diferente de modelo linear generalizado (Nelder; Wedderburn, 1972; McCullagh; Nelder, 1989): a infestação pela broca é uma **contagem** sob esforço amostral variável; a severidade da ferrugem é uma **proporção contínua** sem denominador; e o padrão de exportação é uma resposta **binária**. Tratar as três com a mesma ferramenta seria ignorar o que a natureza de cada dado impõe. Portanto, cada pergunta se transformou em um desafio particular a ser tratado conforme suas especificidades.

Após a análise exploratória univariada¹, este relatório apresenta os três desafios cada um com as respectivas famílias de modelos, o processo de seleção de variáveis, o diagnóstico de resíduos e a recomendação de manejo.

2 Análise exploratória de dados

2.1 Variáveis categóricas de manejo e produção

regiao_produtores: 99 talhões em Sul de Minas (moda), 92 em Cerrado Mineiro, 82 em Mogiana e 67 em Matas de Minas (Figura 1a).

cultivar: 118 talhões com Mundo Novo (moda), 106 com Catuaí, 62 com Icatu e 54 com Bourbon (Figura 1b).

manejo: 166 talhões em manejo convencional (moda), 122 em integrado e 52 em orgânico (Figura 1c).

irrigacao: predominam 202 talhões sem irrigação (moda) frente a 138 irrigados (Figura 1d).




Figura 1: Frequência absoluta das variáveis categóricas.

2.2 Variáveis quantitativas de solo, clima e manejo

altitude_m: variou de 496 a 1343 m ($\bar{x} = 937,1$ m e $s = 156,5$ m), com maior concentração entre 830 e 1046 m – faixa compatível com os 500–1200 m descritos para o

¹Acesse a análise exploratória completa no repositório do projeto.

parque cafeeiro de Minas Gerais (Bernardes *et al.*, 2012) (Figura 2).




Figura 2: Distribuição da altitude (m).

declividade_pct: variou de 1% a 51,4% ($\bar{x} = 19,9\%$ e $s = 8.43\%$), com predomínio de terrenos forte-ondulados (INPE, 2023); esse resultado diverge da faixa de 5% a 15% (Bernardes *et al.*, 2012) para a região (Figura 3).




Figura 3: Distribuição da declividade (%). Predomínio de terrenos forte-ondulados.

idade_lavoura_anos: variou de 1 a 31,1 anos ($\bar{x} = 9,25$ anos e $s = 4.95$ anos), com predomínio de lavoura adulta a partir de dois anos (Nascimento *et al.*, 2019), embora a maioria dos talhões seja mais jovem que os 10 a 30 anos de permanência típicos (Silva; Salvador; Pádua, 2000) (Figura 4).




Figura 4: Distribuição da idade da lavoura (anos).

densidade_plantio: predomínio do sistema semi-adensado (302 talhões), seguido de tradicional (26) e adensado (12), conforme os limiares de classificação (Malta *et al.*, 2005) (Figura 5).




Figura 5: Talhões por classe de densidade de plantio. Predomínio semi-adensado.

adubacao_n_kg_ha: variou de 40 a 532 kg/ha ($\bar{x} = 315,8$ kg/ha e $s = 89.39$ kg/ha), com distribuição aproximadamente bimodal; 50% dos talhões receberam entre 257 e 384 kg/ha (Figura 6).




Figura 6: Distribuição da adubação nitrogenada (kg/ha).

precipitacao_safra_mm: variou de 833 a 2208 mm, com $\bar{x}$ de 1450 mm e s de 246,3 mm (Figura 7).




Figura 7: Distribuição da precipitação na safra (mm).

umidade_relativa_pct: variou de 49,4% a 92,2%, com $\bar{x}$ de 74,0% e s de 6.65% (Figura 8).




Figura 8: Distribuição da umidade relativa (%). Média = 74,0%.

ph_solo: variou de 4,28 a 6,66 ($\bar{x} = 5,43$ e $s = 0.44$), caracterizando acidez média e posicionando os solos no limite superior da classe de qualidade baixa segundo os critérios agrônômicos (Mesquita *et al.*, 2016) (Figura 9).




Figura 9: Distribuição do pH do solo, por classe.

materia_organica_pct: variou de 0,80% a 5,04% ($\bar{x} = 2,75\%$ e $s = 0.78\%$), enquadrando-se na classe de fertilidade média (Mesquita *et al.*, 2016) (Figura 10).




Figura 10: Distribuição da matéria orgânica (%), por classe.

2.3 Variáveis de monitoramento da broca-do-café

n_armadilhas: variou de 4 a 12 armadilhas por talhão; moda e mediana iguais a 8 (Figura 11a).

dias_exposicao: concentrou-se em três valores – 15, 20 e 30 dias –, sendo 15 dias o mais frequente (140 talhões) (Figura 11b).

n_brocas_capturadas: variou de 0 a 62 brocas; moda de 4 e mediana de 6, com distribuição assimétrica à direita (Figura 11c).




Figura 11: Frequência absoluta – monitoramento da broca-do-café.

3 Desafio A — infestação pela broca

A análise² teve como objetivo identificar quais condições de talhão favorecem a infestação pela broca-do-café e quantificar o efeito de cada uma dessas condições sobre a pressão de praga, medida pelo número de brocas capturadas (*n_brocas_capturadas*). Inicialmente, foi realizada uma análise exploratória multivariada, avaliando as associações da variável resposta com as nove variáveis candidatas por meio dos coeficientes de correlação de Pearson, Kendall e Spearman, complementados por uma matriz de correlação global com teste de significância (Figura 12). Essa etapa exploratória indicou uma associação moderada e positiva entre o número de brocas capturadas e a umidade relativa (0.36), além de associações fracas, mas significativas, com as demais variáveis, exceto declividade, idade da lavoura e ph do solo, orientando a construção de uma sequência de modelos: partindo de um modelo nulo (mod00), avançando para modelos completos com todas as covariáveis (mod01 a mod04), testando-se a incorporação do esforço amostral, e culminando em modelos de seleção de variáveis via critério de informação de Akaike (AICc) e em modelos finais mais parcimoniosos, tanto sob a distribuição Poisson (mod05 e mod06) quanto, posteriormente, sob a distribuição binomial negativa (mod07 a mod10), em razão da superdispersão identificada nos dados.

²Acesse a análise completa no repositório do projeto.




Figura 12: Matriz de correlação global com teste de significância entre a variável resposta ($n_brocas_capturadas$) e as variáveis candidatas.

3.1 O esforço amostral e o *offset*

A contagem de brocas depende de quantas armadilhas foram instaladas e por quantos dias. Um talhão com esforço seis vezes maior tende a capturar mais insetos sem que a infestação seja maior. Como o número de brocas capturadas depende também do esforço de amostragem empregado em cada talhão, essa medida foi incorporada aos modelos de duas formas alternativas: como termo de *offset* (coeficiente fixado em 1, na escala logarítmica) e como preditor livre (com coeficiente estimado livremente). O modelo nulo com o esforço amostral como *offset* (mod02) e o modelo completo correspondente (mod03) reduziram a deviança nula em 36,22%, contra uma redução de 29,84% observada no modelo completo sem essa medida (mod01), evidenciando um ganho de 6,38 pontos percentuais na capacidade explicativa ao se considerar o esforço amostral. Em seguida, ajustou-se um modelo com o esforço amostral como preditor livre (mod04), cujo coeficiente estimado (0,901) mostrou-se muito próximo de 1, sustentando a adequação de se fixar esse coeficiente em 1 por meio de um termo de *offset*. Essa adequação caracteriza um modelo de taxa em que a contagem de brocas continua sendo modelada como variável resposta de um modelo Poisson, sem a necessidade de estimar um parâmetro adicional para o esforço amostral (Faraway, 2006). Portanto, com um modelo de taxa, a quantidade de interesse é a taxa de captura por unidade de esforço, μ/E , e não a contagem:

$$\log\left(\frac{\mu_i}{E_i}\right) = \mathbf{x}_i' \boldsymbol{\beta} \iff \log(\mu_i) = \log(E_i) + \mathbf{x}_i' \boldsymbol{\beta}, \quad (1)$$


com $E_i = n_armadilhas_i \times dias_exposicao_i$. O termo $\log(E_i)$ entra com coeficiente fixado em 1 — é um *offset*, não um preditor, e por isso não consome graus de liberdade.

A partir do modelo completo com o esforço amostral como *offset* (mod03), foram ajustados iterativamente todos os subconjuntos possíveis de covariáveis (*dredge*), e o modelo de menor AICc (mod05) coincidiu com o próprio modelo completo (mod03), mantendo as


nove covariáveis. Como declividade e pH do solo não apresentaram efeito estatisticamente significativo em mod05, ajustou-se um modelo final apenas com as seis variáveis de efeito significativo — adubação, altitude, densidade de plantio, idade da lavoura, matéria orgânica e umidade relativa —, denominado mod06. Embora a redução da deviança nula de mod06 (35,96%) tenha sido ligeiramente inferior à de mod05 (36,22%), o modelo mod06 apresentou AICc menor (2261,2 contra 2263,1), sendo por isso preferido como modelo Poisson mais parcimonioso.

3.2 Da Poisson à binomial negativa


A Poisson impõe $\text{Var}[y] = \mathbb{E}[y]$ enquanto que a binomial negativa admite $\text{Var}[y] = \mu + \mu^2/\theta$ (Faraway, 2006). O diagnóstico de equidispersão revelou que a razão entre variância e média das contagens brutas foi de 3,51. Os testes formais (*dispersiontest*) confirmaram superdispersão tanto sob a hipótese de variância linear ($\alpha = 2,08$; $p < 0,001$) quanto quadrática ($\alpha = 0,20$; $p < 0,001$), e o parâmetro de dispersão de Pearson estimado para mod06 (3,17) foi superior a 1.




(a) Frequências observadas vs. esperadas – Poisson



(b) Resíduos – Poisson



(c) Frequências observadas vs. esperadas – Binomial Negativa



(d) Resíduos – Binomial Negativa

Figura 13: Comparação entre as frequências relativas observadas e esperadas do número de brocas capturadas, e respectivos resíduos, sob os modelos Poisson e Binomial Negativa.

Diante dessas evidências, e também da inspeção visual do desencaixe entre as frequências observadas e esperadas, bem como aumento de resíduos sob Poisson quando comparado à binomial negativa (Figura 13), optou-se por abandonar o primeiro e adotar o segundo para a modelagem da contagem de brocas capturadas.

3.3 Definição do modelo binomial negativo final (mod10) e análise de resíduos

Repetindo a mesma lógica de seleção de variáveis, o modelo binomial negativo completo com esforço amostral como offset (mod08) foi submetido ao procedimento de *dredge*, resultando em um modelo de AICc mínimo (mod09) com as mesmas nove covariáveis originais. Como declividade, pH do solo e precipitação da safra não apresentaram efeito estatisticamente significativo em mod09, ajustou-se um modelo final com adubação, altitude, densidade de plantio, idade da lavoura, matéria orgânica e umidade relativa —, denominado mod10. A Figura 14 ilustra os efeitos das variáveis nos modelos mod09 e mod10, respectivamente.




Figura 14: Efeitos das variáveis predictoras nos modelos mod09 e mod10.

Esse modelo apresentou AICc ligeiramente menor (1950,1) do que mod09 (1956,0), sendo então adotado como modelo final, com um teste de razão de verossimilhanças frente ao modelo nulo (mod07) altamente significativo ($LR = 133,39$; 6 g.l.; $p < 0,001$).

O diagnóstico de resíduos de mod10 indicou, pelo gráfico meia-normal dos resíduos *rstudent*, a presença de valores atípicos preditos, principalmente para os talhões 213 e 287. Ou seja, a resposta (número de brocas) não combinou com o que era esperado. Pelo gráfico meia-normal dos valores de alavancagem (*leverage*), foram identificados talhões com condições atípicas, isto é, quanto à combinação de valores das variáveis predictoras (leverage), principalmente nas observações 85 e 148, considerando o ponto de corte de alavancagem de 0,0353. Em outras palavras, houve casos de talhões que se diferiram muito dos demais. Pela distância de Cook, as observações 84 e 272 destacaram-se como

muito acima das demais, indicando influência global relevante dessas observações sobre o ajuste do modelo e sua capacidade preditiva. A Figura 15 ilustra os diagnósticos.




Figura 15: Gráficos meia-normal de diagnóstico de resíduos para o modelo binomial negativa final (mod10).

3.4 Parecer

As razões de taxa (*rate ratios*) apresentadas a seguir foram obtidas pela exponenciação dos coeficientes estimados do modelo binomial negativa final (mod10),

$$RT_j = e^{\hat{\beta}_j}, \quad (2)$$

de modo que cada razão de taxa expressa o fator multiplicativo pelo qual a taxa esperada de captura de brocas se altera a cada aumento de uma unidade na respectiva variável preditora j , mantendo as demais covariáveis e o esforço amostral constantes. Valores de RT_j acima de 1 indicam aumento percentual na pressão de praga, enquanto valores abaixo de 1 indicam redução, sendo a magnitude desse efeito percentual calculada como

$$\Delta\%_j = (RT_j - 1) \times 100\%. \quad (3)$$

Portanto, as condições de talhão que favorecem a infestação pela broca e o quanto se ganha ou se perde em pressão de praga ao alterar cada uma delas, mantendo as demais variáveis e o esforço amostral constantes, são:

- **Adubação nitrogenada:** cada aumento de 1 kg/ha reduz a pressão de praga em aproximadamente 0,08% (razão de taxa = 0,9992). Ou seja, a adubação nitrogenada atua como fator de proteção, e não de risco.
- **Altitude:** cada aumento de 1 metro reduz a taxa de captura em aproximadamente 0,11% (razão de taxa = 0,9989). Talhões em altitudes maiores tendem a apresentar menor pressão de praga.

- **Densidade de plantio:** cada planta adicional por hectare aumenta a pressão de praga em aproximadamente 0,02% (razão de taxa = 1,0002). O efeito é estatisticamente significativo, porém de magnitude muito pequena por unidade.
- **Idade da lavoura:** cada ano adicional de idade aumenta a pressão de praga em aproximadamente 1,73% (razão de taxa = 1,0173).
- **Matéria orgânica do solo:** cada aumento de 1 ponto percentual de matéria orgânica aumenta a pressão de praga em aproximadamente 14,04% (razão de taxa = 1,1403). Este é um dos efeitos de maior magnitude entre os preditores significativos.
- **Umidade relativa:** cada aumento de 1 ponto percentual de umidade aumenta a pressão de praga em aproximadamente 5,00% (razão de taxa = 1,0497), consistente com a associação moderada e positiva identificada na análise exploratória.
- **Declividade, pH do solo e precipitação da safra** não apresentaram efeito estatisticamente significativo sobre a taxa de captura (intervalos de confiança de 95% contendo o valor 1).

4 Desafio B — severidade da ferrugem

4.1 Por que não binomial nem regressão linear

A severidade foi medida como fração de área foliar comprometida por análise de imagem. **Não existe denominador:** não se contaram folhas lesionadas de um total de N . Os 340 valores ocupam 320 níveis distintos no intervalo $[0,0010; 0,6098]$, sem nenhuma observação exata em 0 ou 1 (0 e 0, respectivamente).

Forçar a família binomial exigiria *inventar* um n . Como a variância binomial é $\mu(1 - \mu)/n$, essa escolha arbitrária propaga-se para toda a inferência: variando o n inventado entre 20 e 2000, o erro-padrão do coeficiente da cultivar varia cerca de dez vezes, sem que dado algum mude. Correções por quase-verossimilhança ou erros-padrão robustos eliminam essa dependência, mas ao custo de abandonar a verossimilhança — e com ela o teste de razão de verossimilhanças que a análise de dispersão exige.

A regressão linear, por sua vez, produz previsões negativas e supõe variância constante, quando a variância de uma proporção é estruturalmente função da média: não há espaço para variar perto dos limites do intervalo.

Resta a transformação arco-seno-raiz, histórica em fitopatologia. Testada nesta base, ela *cumpr*e o que promete: estabiliza a variância e remove a não-linearidade. O argumento contra ela é outro. Primeiro, a volta à escala original é enviesada pela desigualdade de Jensen. Segundo, e decisivo, o modelo linear transformado não possui parâmetro

de dispersão a ser modelado, o que inviabiliza a exigência literal da terceira tarefa do enunciado — ajustar um preditor para ϕ e compará-lo por razão de verossimilhanças.

A nota do enunciado pede ainda que se discuta o que fazer diante de zeros exatos. Esta base não os tem (0 ocorrências), mas a regressão beta padrão não os admite, porque a log-verossimilhança avalia $\log(y)$. Havendo talhões com severidade nula, duas saídas se apresentam: a transformação de Smithson e Verkuilen (2006), que comprime a resposta para dentro do intervalo aberto, ou um modelo inflacionado de zeros. A primeira é conveniente mas *ad hoc* — trata a imunidade total como um grau muito pequeno de doença. A segunda é biologicamente mais honesta: separa a probabilidade de a doença se instalar, modelada por regressão logística, da severidade dado que se instalou, modelada pela beta. São dois processos distintos, e o custo é o dobro de parâmetros.

4.2 Regressão beta

Adotou-se a regressão beta na parametrização de Ferrari e Cribari-Neto (2004), implementada por Cribari-Neto e Zeileis (2010), em que $\mathbb{E}[y] = \mu$ e $\text{Var}[y] = \mu(1 - \mu)/(1 + \phi)$, com ϕ interpretado como *precisão*: quanto maior, mais concentrada a distribuição em torno de μ . A variância depende da média por construção, e o problema estrutural do modelo linear desaparece.

A ligação foi escolhida por critério explícito, e não por ser o padrão do pacote. Comparadas as seis ligações disponíveis, 4 ficam dentro de $\Delta\text{AIC} < 2$ e os dados não as distinguem; a diferença estimada entre cultivares permanece entre 11,0 e 12,9 pontos percentuais qualquer que seja a escolha. A `cauchit` foi eliminada por ajuste (ΔAIC 18,17) e a `log` por garantir apenas o limite inferior do intervalo. Entre as restantes, adotou-se a `logit` por ser a única cujos coeficientes exponenciados correspondem a razões de chances.




Figura 16: Faixa de previsões das três abordagens contra o domínio válido da severidade. O modelo linear invade a região impossível abaixo de zero; a regressão beta não pode sair do intervalo, por construção.

4.3 Dispersão constante

O enunciado pede que se investigue se ϕ é constante. Ajustou-se um modelo com preditor também para a precisão e comparou-se por razão de verossimilhanças. Nenhuma covariável, isolada ou em conjunto, rejeitou a constância: para a cultivar, $LR = 3,344$ com $p = 0,342$.

A sustentação positiva vem do exame direto dos resíduos padronizados: ao longo de cinco faixas do valor ajustado, a média varia 4,5 vezes e a variância bruta 4,7 vezes, enquanto o desvio dos resíduos varia apenas 1,210 vezes, sem que os testes de Bartlett ($p = 0,543$) ou de Brown-Forsythe ($p = 0,552$) acusem heterogeneidade. Adotou-se, portanto, ϕ constante, estimado em 20,20.

Registre-se o alcance dessa conclusão: o intervalo de confiança das razões de ϕ entre cultivares vai de 0,57 a 2,31. Descarta-se variação ampla de precisão, não qualquer variação.

4.4 Seleção e efeitos

A seleção *backward* por razão de verossimilhanças reduziu o modelo de 19 para 10 parâmetros, com melhora simultânea de AIC ($-879,47 \rightarrow -889,18$) e BIC ($-802,89 \rightarrow -847,06$). O modelo final alcança pseudo- R^2 de 0,4980.

Em razões de chances, tomando a Bourbon como referência, a Icatu apresenta $OR = 0,2779$ com intervalo de 95% de $[0,2200; 0,3510]$ — a cultivar mais resistente da base,

com chance de adoecimento cerca de quatro vezes menor. Catuaí (0,5983) e Mundo Novo (0,7339) situam-se entre os dois extremos, e os três intervalos excluem a unidade.

4.5 Efeitos marginais em cenários agronômicos

Razão de chances não é probabilidade, e a ligação **logit** é não linear: o mesmo coeficiente vale diferentes pontos percentuais conforme o nível das demais covariáveis. A recomendação ao produtor exige, portanto, a escala original. Fixando as covariáveis numéricas e variando apenas umidade relativa e densidade de plantio, obtêm-se três cenários:

Tabela 1: Severidade esperada por cenário, em pontos percentuais de área foliar.

Cenário	Bourbon	Icatu	Diferença
Desfavorável à doença (decil 10)	—	—	8,0 p.p.
Típico (medianas)	20,80%	6,82%	13,97 p.p.
Favorável à doença (decil 90)	—	—	22,0 p.p.

A escolha de cultivar vale, portanto, entre 8,0 e 22,0 pontos percentuais de severidade, conforme o microclima do talhão. O ganho é maior justamente onde a pressão de doença é maior — o que orienta a priorização: substituir cultivar compensa mais em baixadas úmidas e plantios adensados.

4.6 Diagnóstico de resíduos

Os cinco itens exigidos foram verificados sobre o modelo final. Os *resíduos quantílicos aleatorizados* (Dunn; Smyth, 1996) contra o preditor linear não exibem padrão sistemático, e a *linearidade* das covariáveis contínuas nessa escala se sustenta. A *verificação de dispersão* é a própria Seção anterior: ϕ constante, com os testes de homogeneidade não rejeitando.

Quanto aos *pontos influentes*, a maior distância de Cook é 0,04027 contra uma média de 0,00322; 23 talhões superam três vezes a média, mas 0 ultrapassam o limiar absoluto de 1, de modo que nenhuma observação exerce alavancagem que justifique exclusão. Os mais salientes são os talhões TAL222, TAL169, TAL241.

O *envelope simulado* por 99 reajustes do próprio modelo deixa 38 dos 340 pontos fora da banda de 95%, ou 11,2%. É mais que os 5% esperados, e coerente com o teste de Shapiro-Wilk sobre os resíduos quantílicos, que rejeita a normalidade estrita ($W = 0,9903$, $p = 0,025$). A assimetria residual é real e concentra-se nos talhões de maior severidade, onde a beta subestima ligeiramente a variância. O desvio não invalida a inferência sobre a cultivar — cujos intervalos são amplos o bastante para absorvê-lo — mas deve ser

registrado como limitação, e sugere que uma extensão com dispersão variável por faixa de média, ainda que rejeitada pelos testes formais, mereça investigação em trabalhos futuros.

5 Desafio C — padrão de exportação

5.1 A resposta, a família e a ligação

Dos 340 talhões, 160 atingem o padrão de exportação e 180 não — prevalência de 47,06%. Cada talhão traz um único resultado 0/1: uma observação de Bernoulli, e não uma contagem de sucessos com denominador conhecido. A variância $\text{Var}[y] = \pi(1 - \pi)$ é determinada pela média, de modo que não há parâmetro de dispersão livre e a superdispersão é inidentificável. Adotou-se a ligação `logit`, canônica da binomial e a única cujos coeficientes exponenciados são razões de chances: as 4 ligações disponíveis ficam dentro de $\Delta\text{AIC} < 2$, e a escolha apoia-se na interpretação, não no ajuste. Com 16 parâmetros admissíveis pela regra de dez eventos por variável (Peduzzi *et al.*, 1996) contra 19 do amplo, selecionar é necessidade, não preferência estética.

5.2 Seleção de variáveis

Ficam fora por construção `n_armadilhas` e `dias_exposicao`, que descrevem o processo de medição; `n_brocas_capturadas`, desfecho do Desafio A; e `severidade_ferrugem`, desfecho do Desafio B, reservada à Seção 5.3. O maior VIF generalizado ajustado é 1,27 (`altitude_m`). A eliminação *backward* por razão de verossimilhanças a 5% retirou 9 termos, de `declividade_pct` a `regiao_produtores`, levando o AIC de 465,29 a 456,63 e o BIC de 538,04 a 487,26. Entre o modelo final, com 8 parâmetros, e o amplo **não se detectou perda de ajuste estatisticamente significativa** ($\text{LR} = 13,34$, $p = 0,272$), o que não demonstra equivalência: apenas que esta amostra não distingue os dois ajustes. A `cultivar` foi retida **por desenho**: é o que o produtor escolhe e a exposição da Seção 5.3.

Três covariáveis — `declividade_pct`, `densidade_plantio`, `precipitacao_safram_m` — reúnem $p > 0,5$ no amplo e saída nos primeiros passos, assim como a taxa de captura de broca oferecida ao modelo final ($p = 0,919$). A leitura é restrita: **nesta amostra e sob estes critérios**, não se encontrou evidência de contribuição depois de consideradas as demais covariáveis — o que não demonstra irrelevância agrônoma, já que efeito pequeno, faixa de variação estreita nesta base ou colinearidade com termos mantidos produziram o mesmo resultado.

5.3 Cultivar e ferrugem: duas leituras do coeficiente

A `severidade_ferrugem` é ela própria um desfecho, influenciada pela cultivar: escolhida a cultivar no plantio, a ferrugem se instala ao longo da safra e a classificação vem

por último. Sob essa ordenação, adotada como **hipótese causal de trabalho**, a severidade ocuparia a posição de mediadora (Pearl, 2009; VanderWeele, 2016). A configuração observada é instrutiva: a Icatu tem *a menor* severidade média (0,067 contra 0,212 da Bourbon) e, simultaneamente, *a menor* chance estimada de exportação. Comparam-se dois modelos: sem a severidade, o coeficiente da Icatu é -0,7531; com ela, -1,3374 — padrão que se repete em Catuaí (-0,1494 para -0,4325) e Mundo Novo (-0,6322 para -0,8448). A própria severidade tem coeficiente -3,9237 ($p = 0,002$): cada 0,10 a mais de área foliar lesionada multiplica a chance por 0,675 ([0,524; 0,859]).

Os rótulos **efeito total** e **efeito direto** são interpretações válidas *sob* o diagrama adotado, e não efeitos causais estabelecidos pela regressão, que estima associações condicionais. Nesses termos, o modelo sem a severidade corresponde ao que o produtor herda ao escolher a cultivar antes do plantio — por isso é o adotado como final —, e o modelo com ela, à pergunta de quem planeja o controle da doença. Duas ressalvas limitam a leitura: a interpretação causal pressupõe ausência de confundidor não medido entre ferrugem e exportação, hipótese não testável com estes dados; e **o deslocamento dos coeficientes não demonstra mediação**, pois a razão de chances não é colapsável (Greenland; Robins; Pearl, 1999) — acrescentar uma covariável associada ao desfecho altera os demais coeficientes mesmo sem qualquer caminho mediado.

5.4 Efeitos, capacidade preditiva e diagnóstico

Tabela 2: Razões de chances do modelo final, com intervalos de verossimilhança perfilada. Referências: Bourbon (cultivar) e convencional (manejo).

Termo	Razão de chances	IC 95%
Cultivar Catuaí	0,861	[0,432; 1,707]
Cultivar Icatu	0,471	[0,215; 1,013]
Cultivar Mundo Novo	0,531	[0,268; 1,042]
Manejo integrado	1,708	[1,046; 2,799]
Manejo orgânico	2,274	[1,185; 4,434]
Altitude (por 100 m)	1,285	[1,108; 1,500]
Idade da lavoura (por 5 anos)	0,764	[0,602; 0,961]

Apenas manejo e contínuas têm intervalos que excluem 1; os da cultivar delimitam a faixa plausível, o que não equivale a ausência de efeito. Razão de chances tampouco é risco relativo: a tradução em pontos percentuais depende do ponto de partida (Seção ??).

A área sob a curva ROC (Figura 17) é 0,673 (IC 95% de DeLong (DeLong; DeLong; Clarke-Pearson, 1988): [0,615; 0,730]) na própria amostra de ajuste, e cai a 0,635 sob

validação cruzada em 10 partes. O alcance desse segundo número precisa ser declarado: a *fórmula* do modelo final foi selecionada previamente com a base completa, e apenas os *coeficientes* são reajustados em cada parte. A estimativa corrige o otimismo do ajuste dos coeficientes, mas **não valida de forma independente o processo de seleção**, que teria de ser repetido dentro de cada parte.

O corte é decisão de custo, e não propriedade do modelo: $p^* = C_{FP}/(C_{FP} + C_{FN})$ vale 0,5 apenas com erros de mesmo custo. Sob $C_{FP} = 2 C_{FN}$ — razão **suposta neste trabalho**, não estimada dos dados, admitindo que um lote rejeitado na exportação custe mais que um prêmio perdido —, ele sobe a 0,667, com especificidade 95,0% e sensibilidade 13,1%. Nesse corte o custo médio *observado nesta amostra* é 0,462 por lote contra 0,471 da regra trivial de nunca apontar lote algum: diferença pequena, medida nos mesmos talhões que ajustaram o modelo e que, por isso, não se pode apresentar como benefício assegurado em novos talhões. O modelo presta-se a *priorizar* talhões, não a substituir a classificação oficial.




Figura 17: Curva ROC do modelo final. Os pontos marcam o corte de 0,5 e o de Youden (0,52); a diagonal corresponde à classificação ao acaso.

O diagnóstico usou resíduos quantílicos aleatorizados (Dunn; Smyth, 1996), compatíveis com $N(0, 1)$ ($p = 0,929$), e envelope simulado por 99 reajustes, em que 0 dos 340 pontos ficaram fora da banda — resultado que indica **ausência de incompatibilidade detectada por este diagnóstico**, e não prova de que o modelo esteja correto. A razão de Pearson sobre os graus de liberdade é 1,03, ainda que não identifique superdispersão em dados binários; o ajuste global veio da calibração por decis ($\chi^2 = 7,29$, $p = 0,505$) (Hosmer; Lemeshow; Sturdivant, 2013). Os 5 talhões acima da régua de $4/n$ (Cook máximo 0,0186; TAL007, TAL017, TAL040 entre eles) não alteram o sinal de nenhum coeficiente quando removidos, e nem $\hat{\eta}^2$ como covariável extra ($p = 0,973$) nem o termo

$x \log x$ ($p = 0,144$ e $p = 0,347$) acusaram inadequação da ligação ou da escala adotadas.

6 Considerações finais

Em síntese, matéria orgânica e umidade relativa são as condições de talhão que mais favorecem a infestação pela broca, enquanto adubação nitrogenada e altitude atuam como fatores de proteção. Densidade de plantio e idade da lavoura apresentam efeitos positivos, porém de magnitude reduzida.

A escolha da cultivar é o fator de maior impacto sobre a ferrugem: 13,97 pontos percentuais de severidade separam a Bourbon da Icatu num talhão típico. Essa vantagem, contudo, não se traduz automaticamente em exportação — a Seção 5.3 mostra que a Icatu carrega uma penalidade direta que compensa parte do ganho fitossanitário. A recomendação de cultivar, portanto, não pode ser derivada apenas do Desafio B.

Na escala que interessa ao produtor, num talhão típico — altitude de 935 m e lavoura de 8,4 anos —, a probabilidade de atingir o padrão de exportação vai de 31,9% (Icatu com manejo convencional) a 69,4% (Bourbon com manejo orgânico). Entre as decisões que estão ao alcance do cooperado, a de maior retorno é o **sistema de manejo**: a passagem do convencional ao orgânico acrescenta de 19,5 a 20,0 pontos percentuais de probabilidade, conforme a cultivar. A **renovação das lavouras mais velhas** vem em seguida: entre o primeiro e o terceiro quartil de idade a probabilidade varia -8,3 pontos percentuais. A altitude não se escolhe, mas orienta *onde* concentrar o esforço — 13,5 pontos percentuais separam os quartis —, indicando os talhões altos como candidatos naturais aos contratos de exportação e os baixos como os que mais dependem do manejo para compensar.

Duas ressalvas delimitam o alcance dessas recomendações. A capacidade preditiva é moderada (AUC 0,635 sob validação cruzada), o que indica que parte relevante do que decide o padrão de exportação não está nas características de talhão desta base — colheita, pós-colheita e beneficiamento não foram medidos. E as associações são observacionais: o modelo não substitui um experimento em que cultivar e manejo sejam atribuídos aos talhões.

Referências

BERNARDES, Tiago *et al.* Diagnóstico físico-ambiental da cafeicultura no Estado de Minas Gerais – Brasil. **Coffee Science**, v. 7, p. 139–151, 2012.

CRIBARI-NETO, Francisco; ZEILEIS, Achim. Beta Regression in R. **Journal of Statistical Software**, v. 34, n. 2, p. 1–24, 2010. DOI: 10.18637/jss.v034.i02.

DELONG, Elizabeth R.; DELONG, David M.; CLARKE-PEARSON, Daniel L. Comparing the Areas under Two or More Correlated Receiver Operating Characteristic Curves: A Nonparametric Approach. **Biometrics**, v. 44, n. 3, p. 837–845, 1988. DOI: 10.2307/2531595.

DUNN, Peter K.; SMYTH, Gordon K. Randomized Quantile Residuals. **Journal of Computational and Graphical Statistics**, v. 5, n. 3, p. 236–244, 1996. DOI: 10.1080/10618600.1996.10474708.

FARAWAY, Julian J. **Extending the Linear Model with R: Generalized Linear, Mixed Effects and Nonparametric Regression Models**. Boca Raton, FL: Chapman & Hall/CRC, 2006. (Texts in Statistical Science). ISBN 978-1-58488-424-8.

FERRARI, Silvia L. P.; CRIBARI-NETO, Francisco. Beta Regression for Modelling Rates and Proportions. **Journal of Applied Statistics**, v. 31, n. 7, p. 799–815, 2004. DOI: 10.1080/0266476042000214501.

GREENLAND, Sander; ROBINS, James M.; PEARL, Judea. Confounding and Collapsibility in Causal Inference. **Statistical Science**, v. 14, n. 1, p. 29–46, 1999. DOI: 10.1214/ss/1009211805.

HOSMER, David W.; LEMESHOW, Stanley; STURDIVANT, Rodney X. **Applied Logistic Regression**. 3. ed. Hoboken: John Wiley & Sons, 2013.

INPE. **Instituto Nacional de Pesquisas Espaciais (INPE) - Divisão de Observação da Terra e Geoinformática (DIOTG). Declividade (6 classes)**. [S. l.]: Infraestrutura de Dados Espaciais do Sistema Estadual de Meio Ambiente e Recursos Hídricos (IDE-Sisema), abr. 2023.

MALTA, Marcelo R. *et al.* Caracterização agrônômica de lavouras cafeeiras cultivadas sob o sistema orgânico no sul de Minas Gerais. **Congresso Brasileiro de Pesquisas Cafeeiras**, p. 399–400, 2005.

MCCULLAGH, Peter; NELDER, John A. **Generalized Linear Models**. 2. ed. London: Chapman e Hall, 1989.

MESQUITA, Carlos Magno de *et al.* **Manual do Café: Manejo de Cafezais em Produção**. [S. l.: s. n.], 2016. p. 1–72.

NASCIMENTO, Jefferson Luiz Marciano do *et al.* Tolerância de plantas jovens de café a herbicidas aplicados isoladamente ou em mistura com o fertilizante Fertiacetyl. **Weed Control Journal**, v. 18, 2019. DOI: 10.7824/rbh.v18i4.681.

NELDER, John A.; WEDDERBURN, Robert W. M. Generalized Linear Models. **Journal of the Royal Statistical Society: Series A (General)**, v. 135, n. 3, p. 370–384, 1972. DOI: 10.2307/2344614.

PEARL, Judea. **Causality: Models, Reasoning, and Inference**. 2. ed. Cambridge: Cambridge University Press, 2009.

PEDUZZI, Peter *et al.* A Simulation Study of the Number of Events per Variable in Logistic Regression Analysis. **Journal of Clinical Epidemiology**, v. 49, n. 12, p. 1373–1379, 1996. DOI: 10.1016/S0895-4356(96)00236-3.

SANTOS, Vladimir Faria dos *et al.* Análise da eficiência técnica de talhões de café irrigados e não-irrigados em Minas Gerais: 2004-2006. **Revista de Economia e Sociologia Rural**, v. 47, p. 677–698, 2009. DOI: 10.1590/S0103-20032009000300007.

SILVA, Fábio Moreira da; SALVADOR, Nilson; PÁDUA, Tassiana de Souza. Café: mecanização da colheita. *In*: I Simpósio de Pesquisa dos Cafés do Brasil. [*S. l.*: *s. n.*], 2000. p. 281–329.

SMITHSON, Michael; VERKUILEN, Jay. A Better Lemon Squeezer? Maximum-Likelihood Regression with Beta-Distributed Dependent Variables. **Psychological Methods**, v. 11, n. 1, p. 54–71, 2006. DOI: 10.1037/1082-989X.11.1.54.

VANDERWEELE, Tyler J. Mediation Analysis: A Practitioner’s Guide. **Annual Review of Public Health**, v. 37, p. 17–32, 2016. DOI: 10.1146/annurev-publhealth-032315-021402.